




APRENDIZAJE NO SUPERVISADO

SOL VICTORIA ANSELMO JULIÁN SASO
AGUSTÍN MATTIUSI CAMILA SIERRA PÉREZ
IAN JAMES ARNOTT
JUAN ADOLFO ROSAUER HERRMANN



Ejercicio 1


DATASET

Contamos con un conjunto de datos correspondiente a características económicas, sociales y geográficas de 28 países de Europa.


Las variables son:

- Country : Nombre del país.
- Area: área
- GDP: producto bruto interno.
- Inflation: inflación anual.
- Life.expect: expectativa de vida media en años.
- Military: presupuesto militar.
- Pop.growth: tasa de crecimiento poblacional.
- Unemployment: tasa de desempleo.

BOXPLOT DE FEATURES



BOXPLOT DE FEATURES



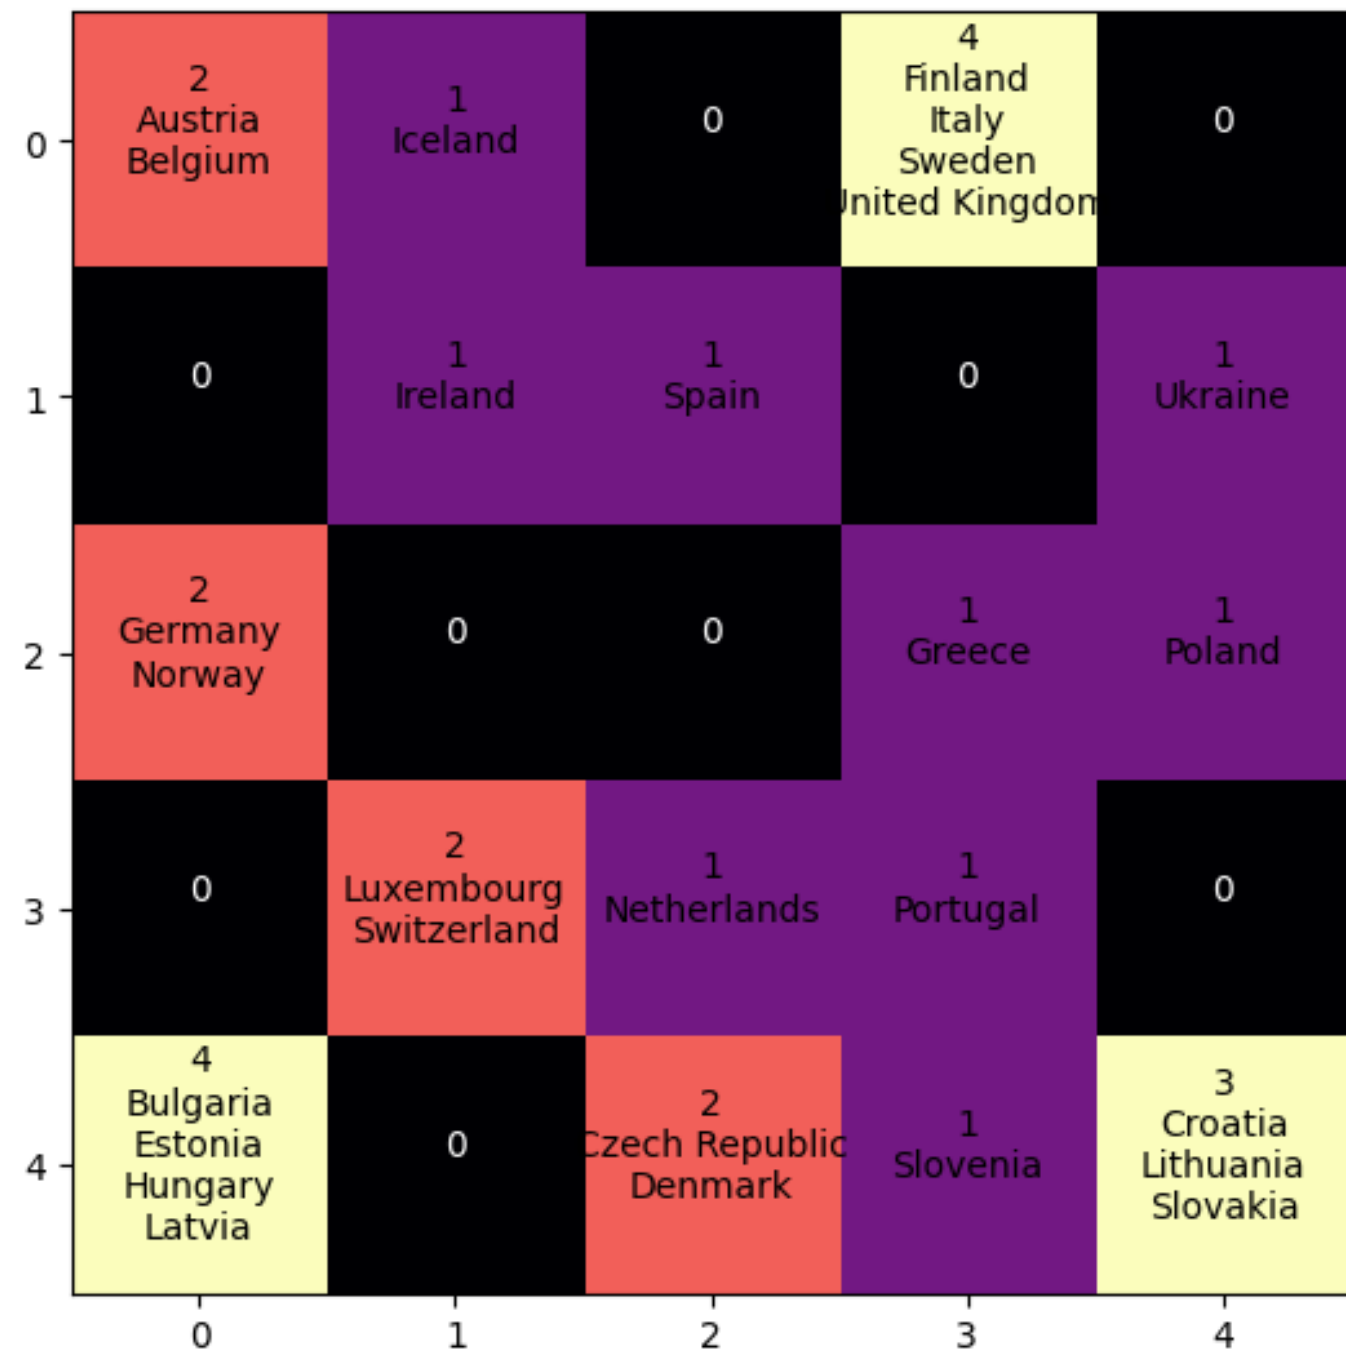
La estandarización
permite ver una
representación más
realista de la
variabilidad de los
datos.

RED DE KOHONEN

**ASOCIAMOS PAÍSES
QUE POSEAN
CARACTERÍSTICAS
SIMILARES**

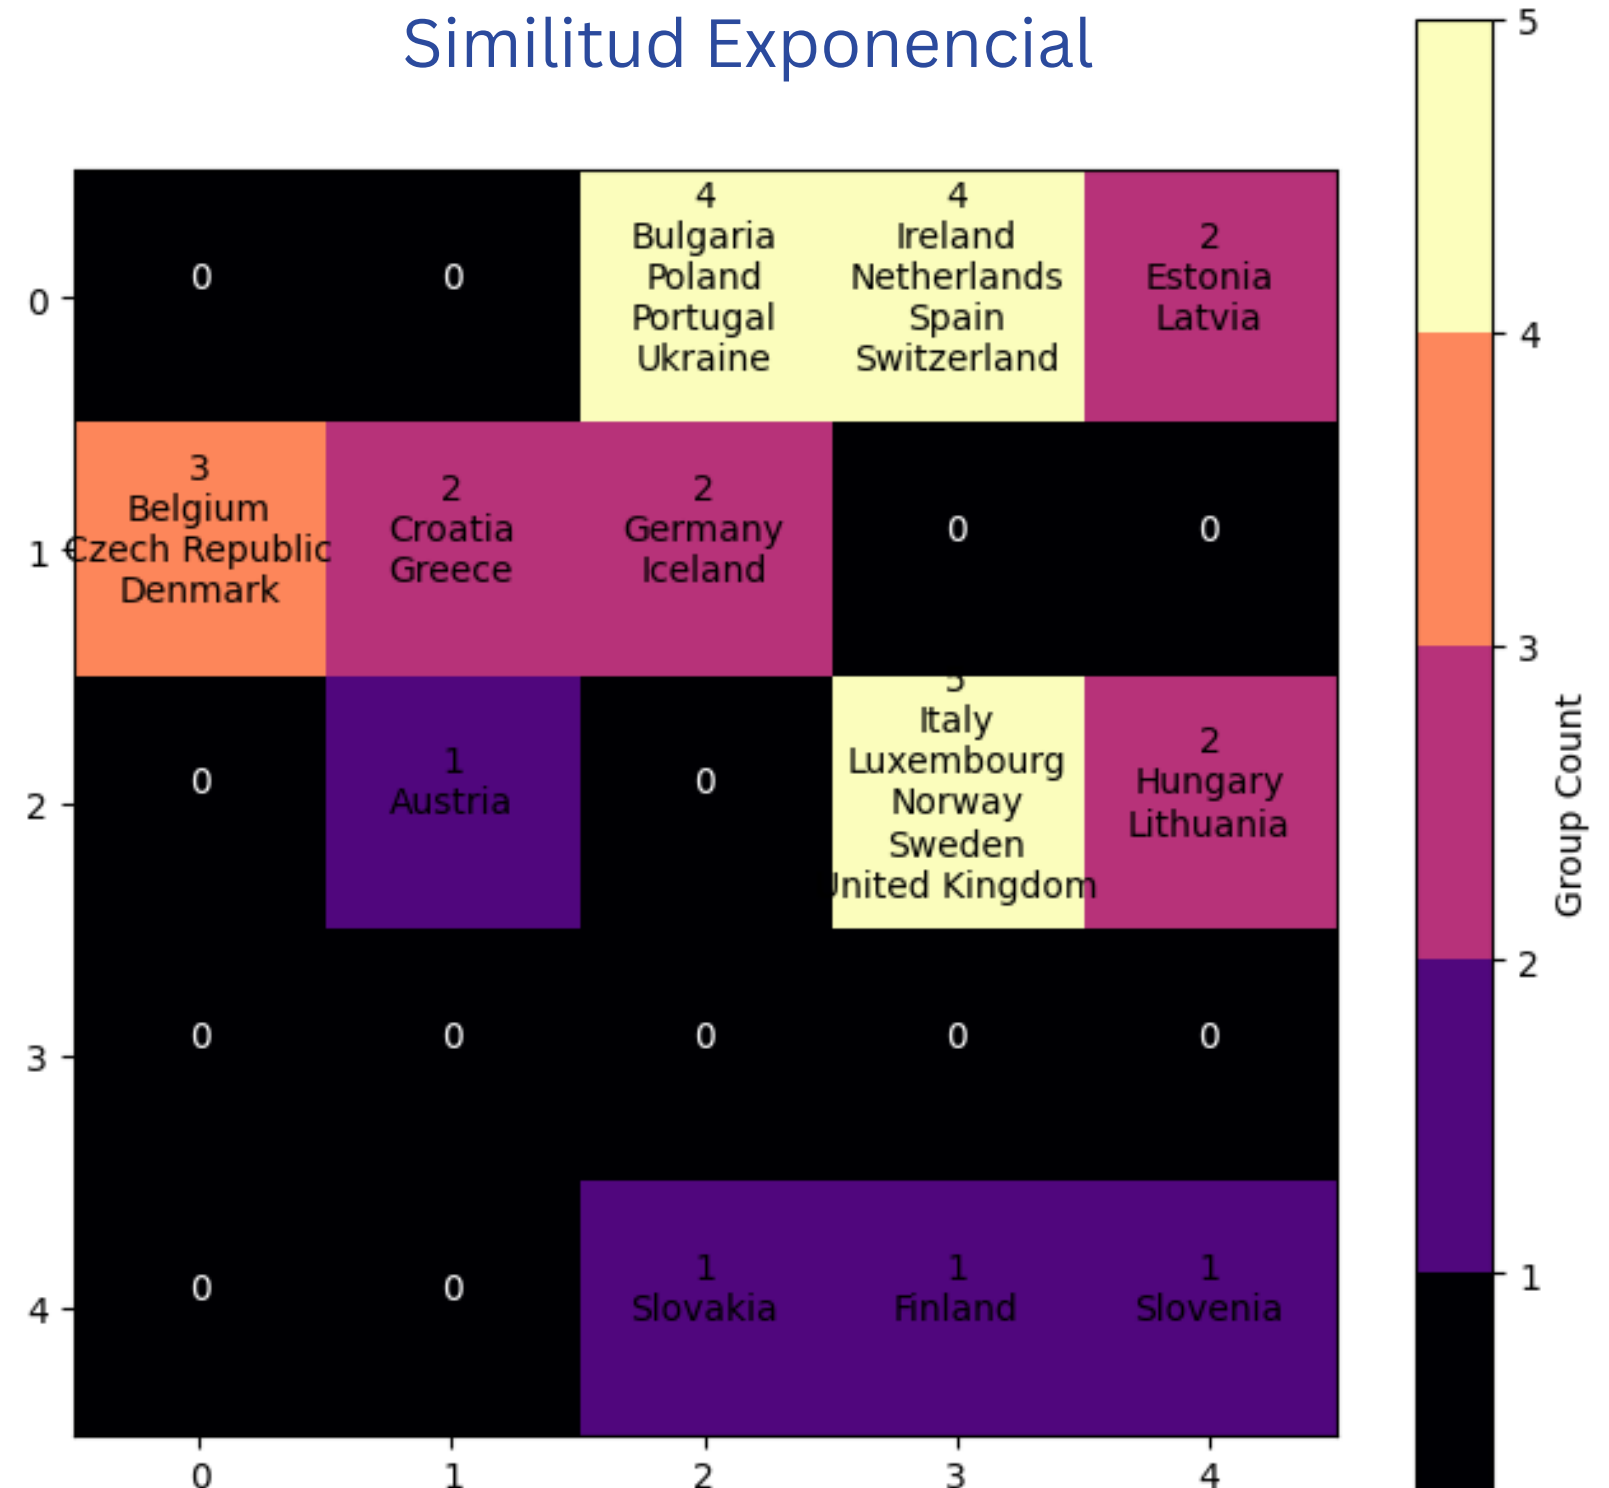
HEATMAP 5X5

Similitud Euclidea



k=5, n = 0.01, R = 10, Epocas = 10000

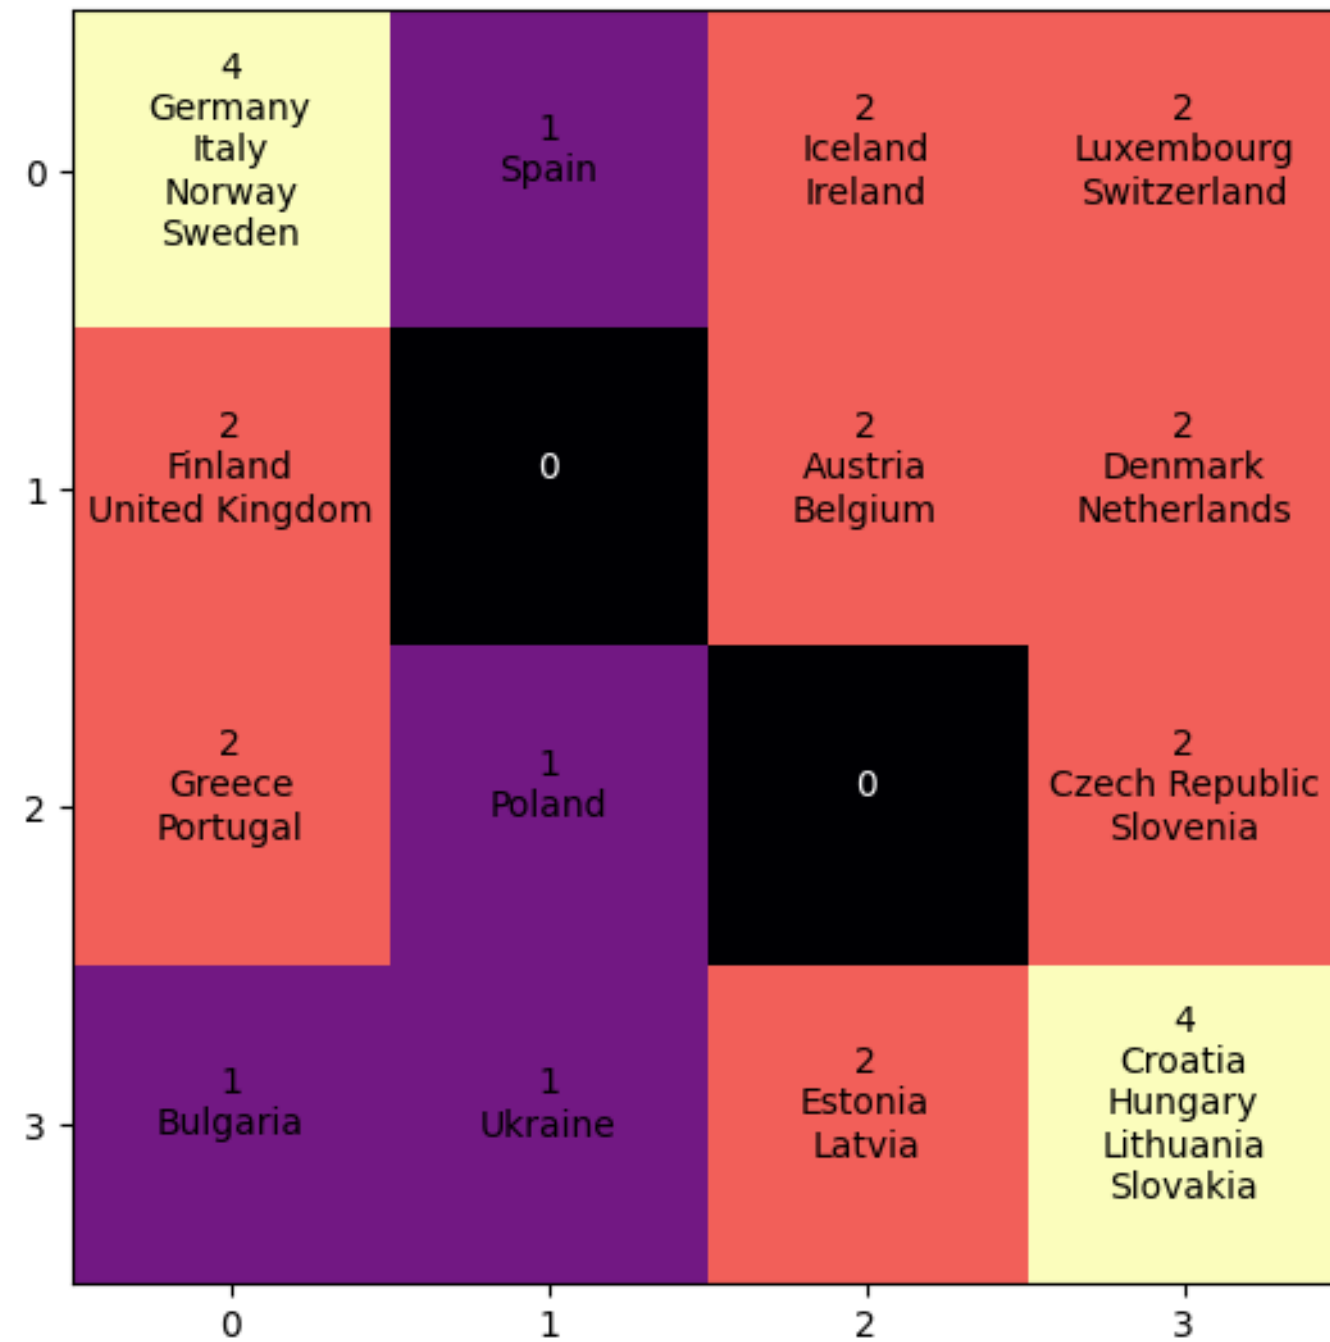
Similitud Exponencial



k=5, n = 0.01, R = 10, Epocas = 10000


HEATMAP 4X4

Similitud Euclidea



k=4, n = 0.01, R = 4, Epocas = 10000

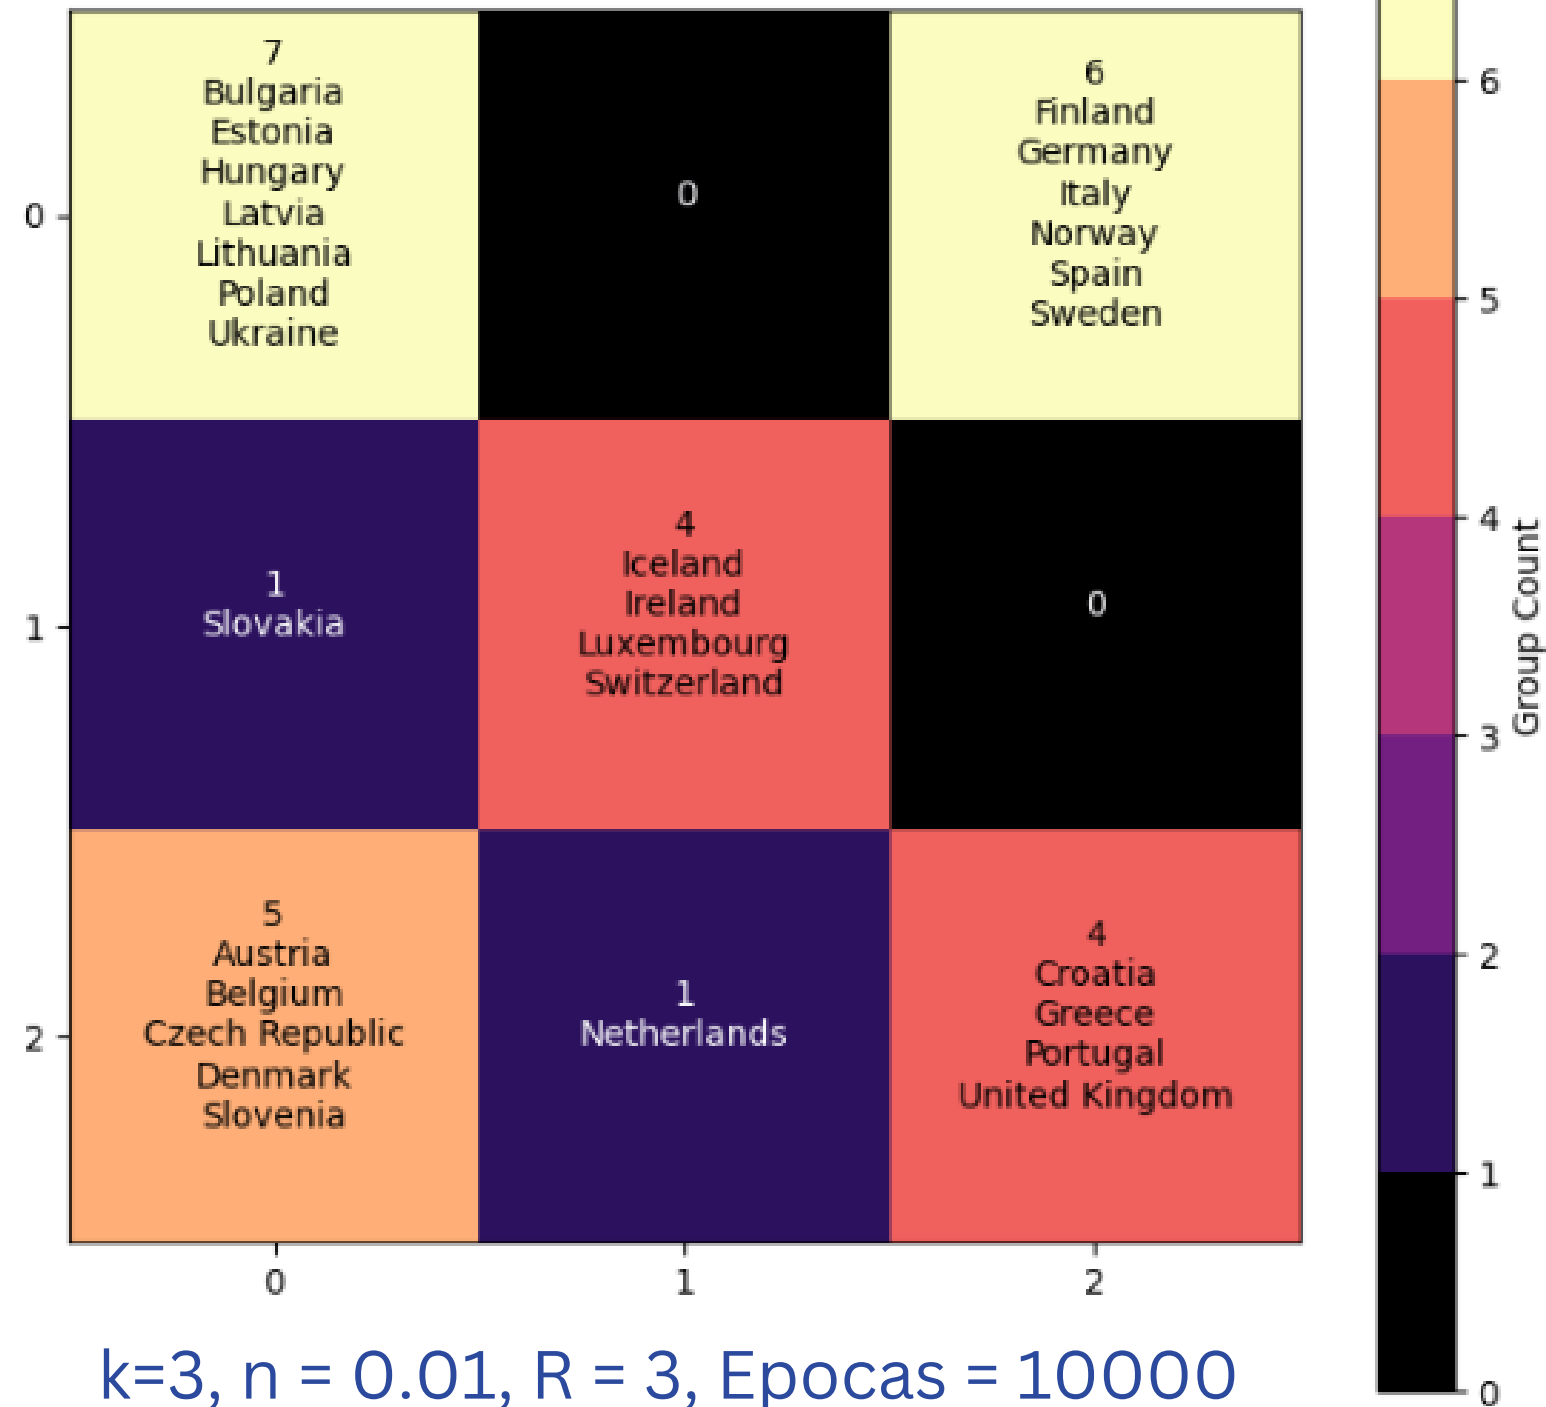
Similitud Exponencial



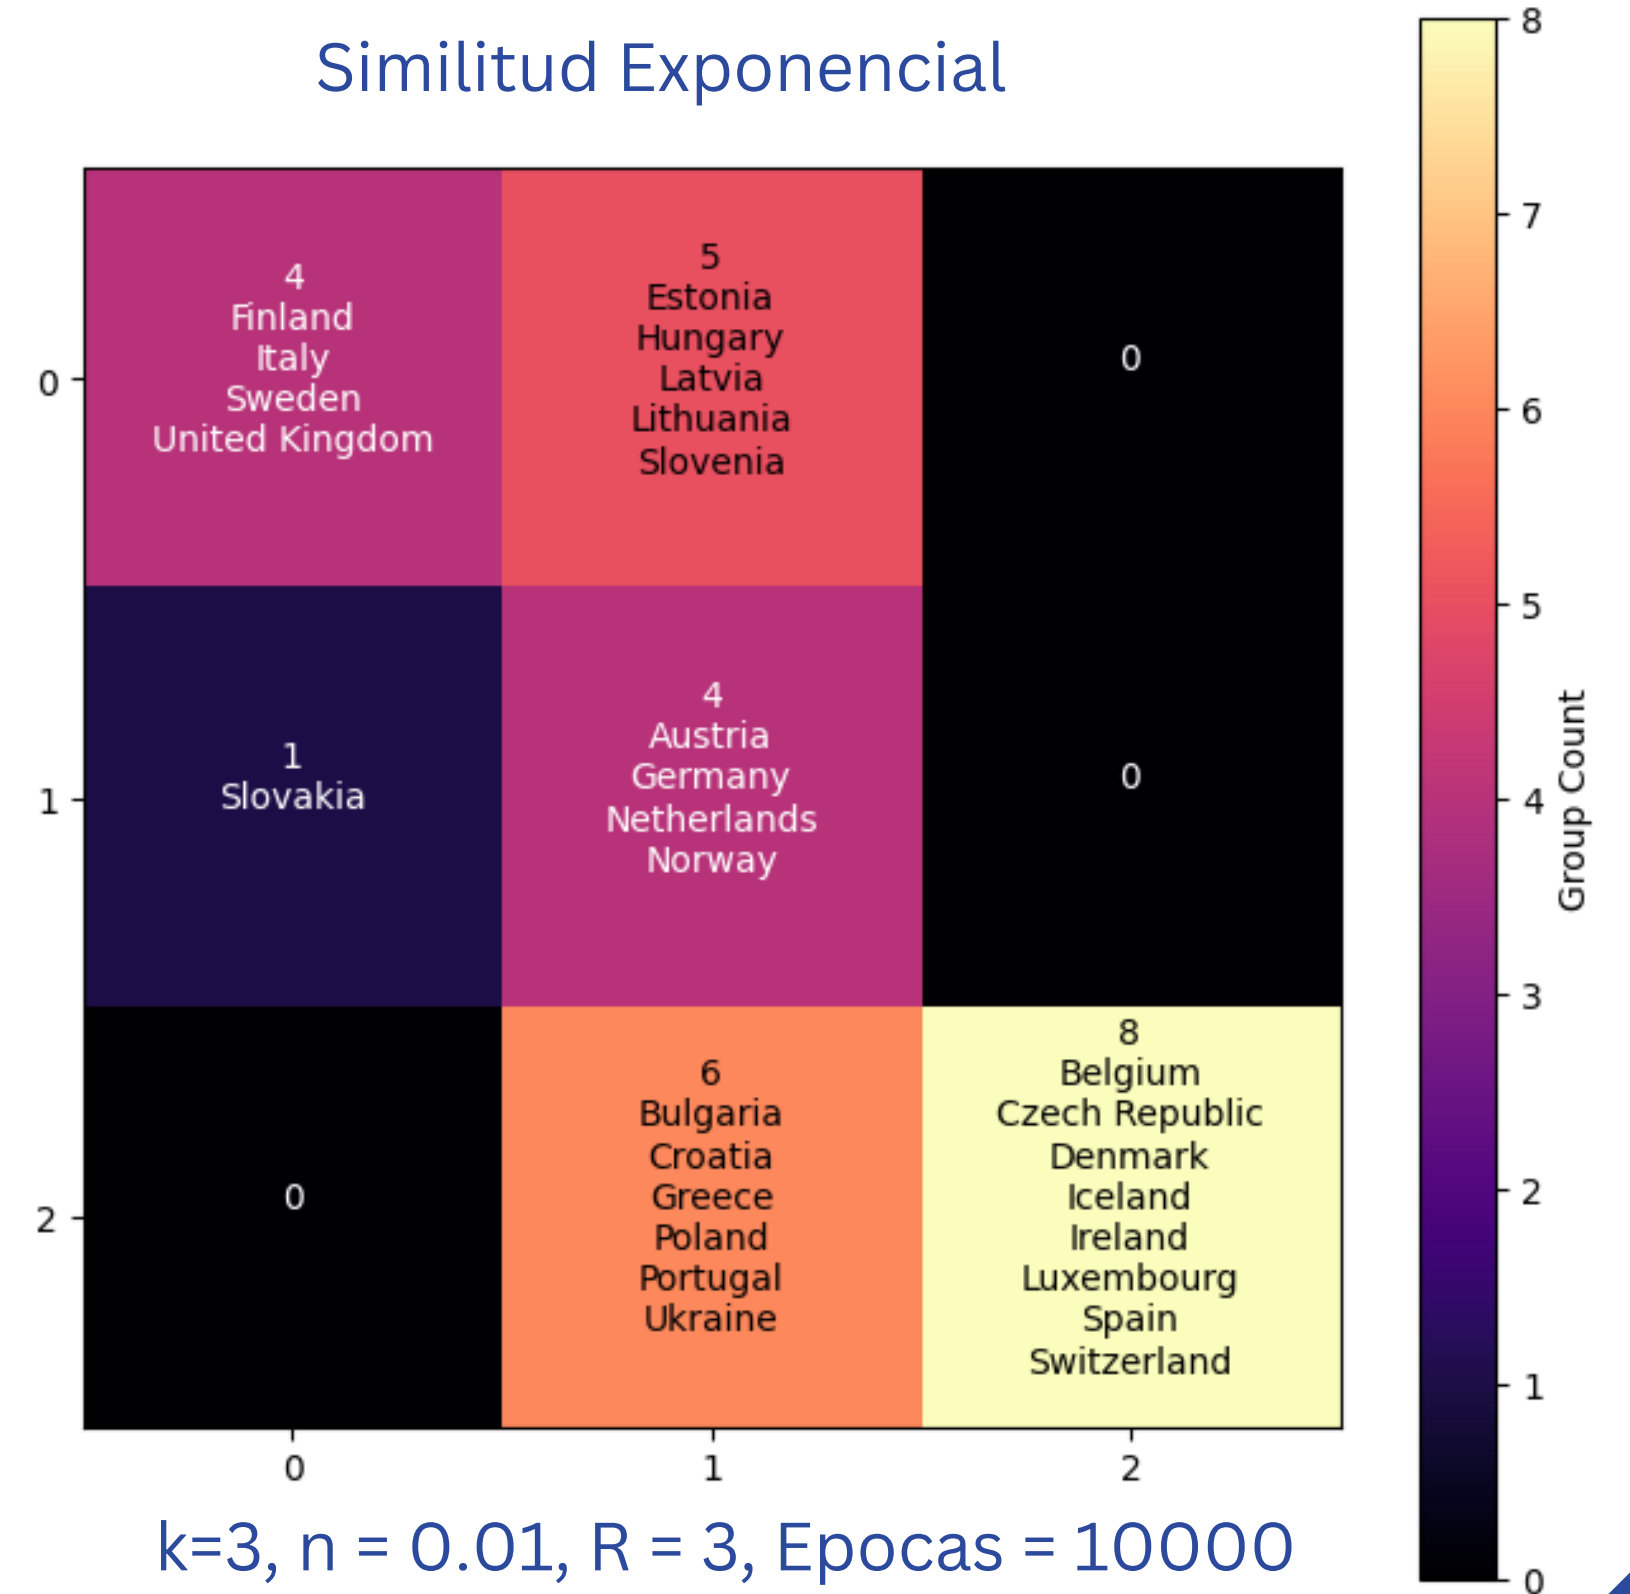
k=4, n = 0.01, R = 4, Epocas = 10000

HEATMAP 3X3

Similitud Euclidea




Similitud Exponencial



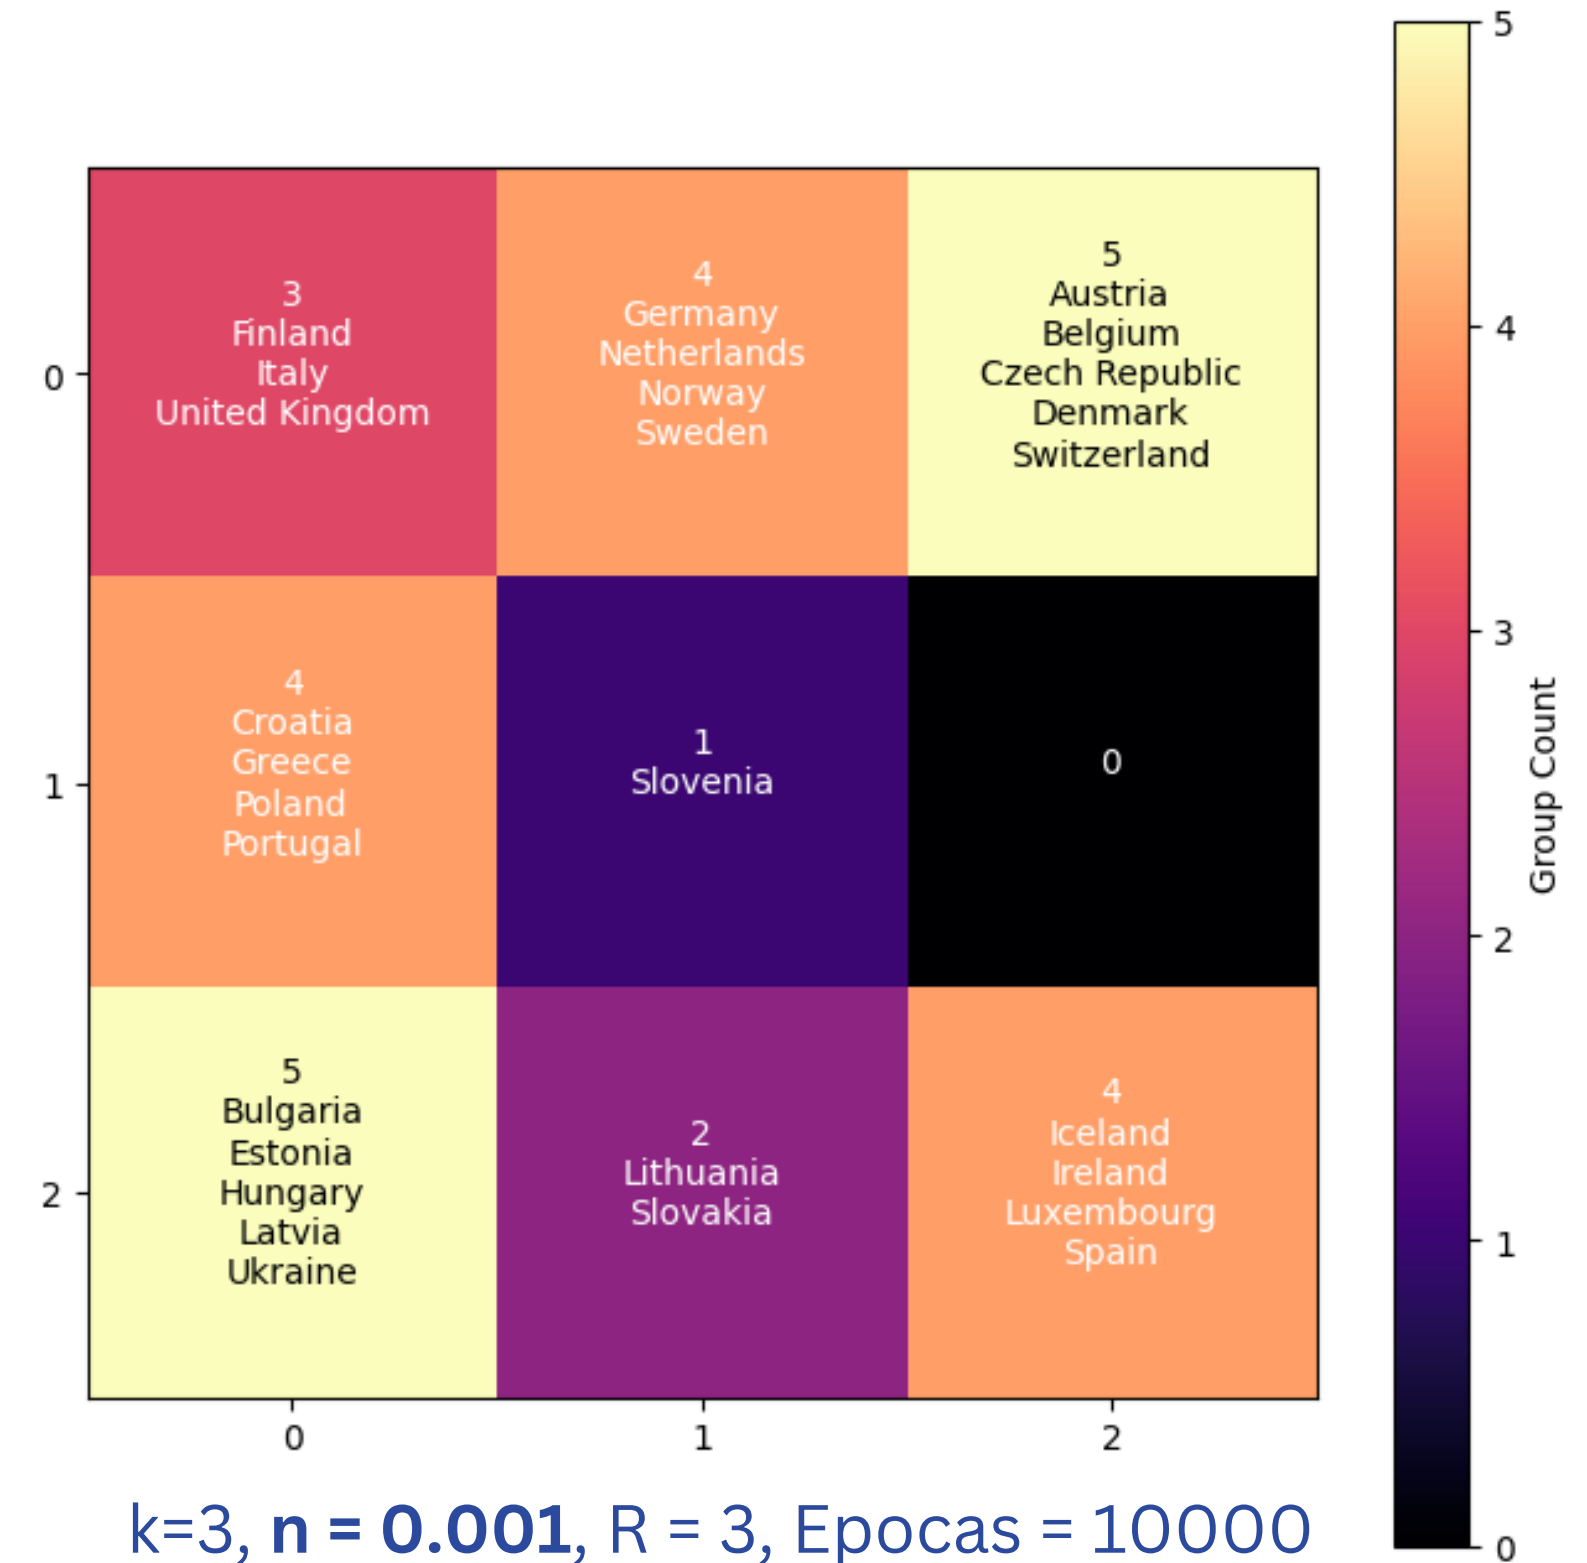
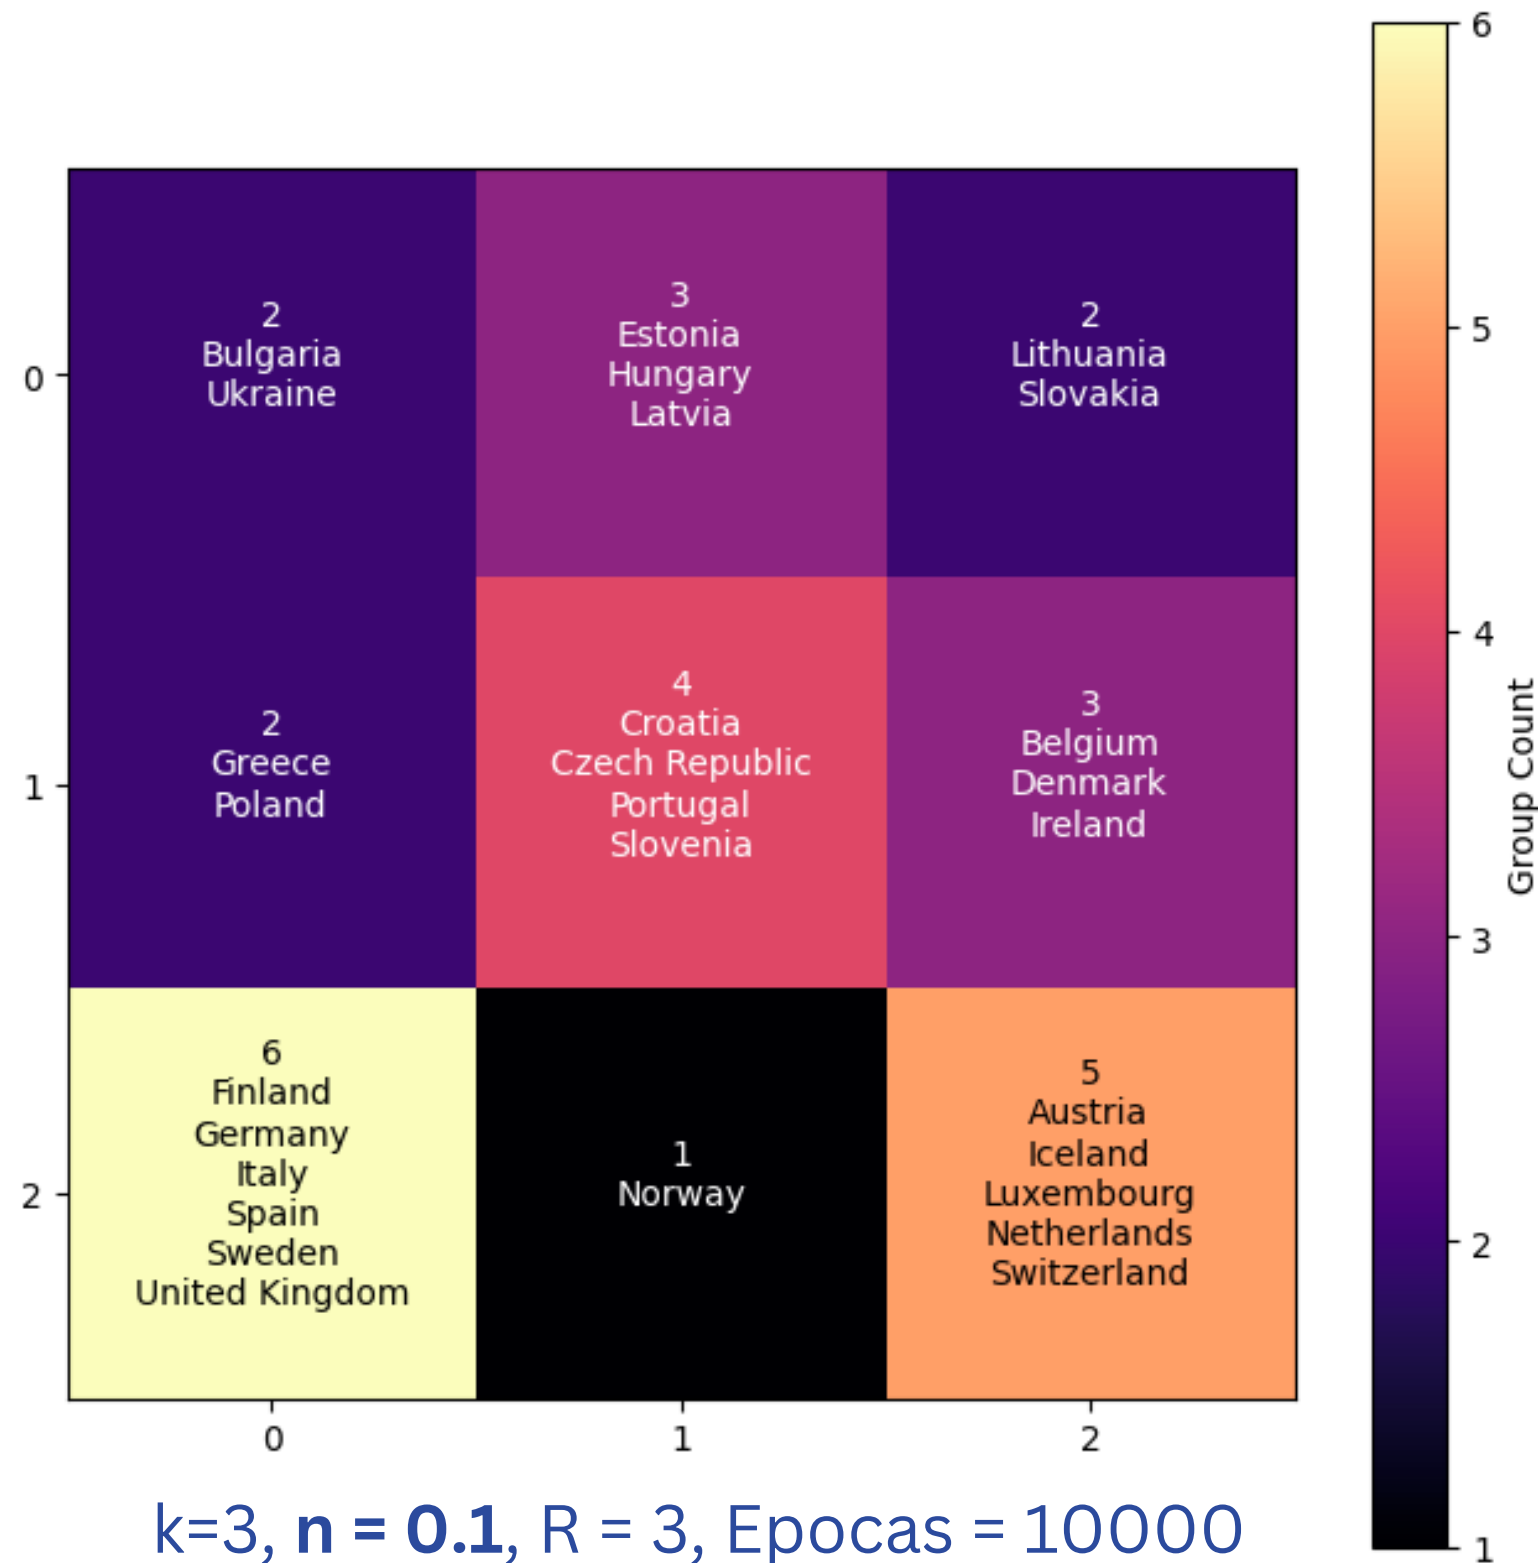
MATRIZ U 3X3

Similitud Euclidea

k=3, n = 0.01, R = 3, Epocas = 10000




VARIANDO LEARNING RATE PARA 3X3



Similitud Euclidea


HEATMAP DE UNA SOLA VARIABLE




k=3, n = 0.01, R = 3, Epocas = 10000
Similitud Euclidea

HEATMAP DE UNA SOLA VARIABLE

"Life.expect" para cada neurona



"Pop.growth" para cada neurona




Los mapas de expectativa de vida y crecimiento poblacional, tienen la activación de neuronas similar, es decir, tienen correlación positiva.


k=3, n = 0.01, R = 3, Epocas = 10000
Similitud Euclidea

HEATMAP DE UNA SOLA VARIABLE

"GDP" para cada neurona



"Unemployment" para cada neurona



Los mapas de inflación y desempleo tienen una correlación negativa con el de GDP, dado que activan neuronas opuestas a las de GDP

k=3, n = 0.01, R = 3, Epocas = 10000

Similitud Euclidea

CONCLUSIONES

A un valor mayor de K , se podrá hacer una clasificación más fina de los países, a coste de tener más neuronas muertas.

La similitud exponencial genera más neuronas muertas que la similitud euclídea, es decir, la similitud exponencial concentra más países por grupo.


No hubo diferencias significativas al variar el Learning Rate.

**MODELO DE
OJA**

**PARA EL ANÁLISIS
DE LA PRIMERA
COMPONENTE**

BIPLOT CON SKLEARN


Biplot de PCA



PC1 separa las variables en dos grupos:

1. Area, Inflation, Military, Unemployment
2. GDP, Life.expect, Pop.growth.

COMPONENTES CON SKLEARN



CARGAS

Area: 0.12487

GDP: -0.500506

Inflation: 0.406518

Life.expect: -0.482873


Military: 0.188112

Pop.growth: -0.475704

Unemployment: 0.271656

COMPONENTES CON OJA

Componente 1 por país - LR: 0.001 - Epochs: 10000



CARGAS

Area: 0.13209

GDP: -0.49984

Inflation: 0.41359


Life.expect: -0.48437

Military: 0.18216

Pop.growth: -0.47415


Unemployment: 0.26813

ERROR PROMEDIO VARIANDO LAS EPOCAS



ERROR PROMEDIO VARIANDO EL LEARNING RATE

Error en función del learning rate para 10000 épocas



CONCLUSIONES

PC1 separa las variables en dos grupos:

1. Area, Inflation, Military, Unemployment.
2. GDP, Life.expect, Pop.growth.

Del gráfico de componentes podemos ver que:

1. Si $PC1 > 0$, al país lo afectan más las variables del grupo 1.
2. Si $PC1 < 0$, al país lo afectan más las variables del grupo 2.

Con una menor tasa de aprendizaje y una mayor cantidad de épocas logramos mejores resultados y convergencia hacia los valores deseados.

Hubo casos en donde el vector de pesos sinápticos de Oja converge a los mismos valores absolutos pero con los signos de todas las componentes invertidas.

Ejercicio 2


MODELO DE HOPFIELD

**SE CREARON MATRICES DE
LETRAS CON 1 Y -1,
ALMACENAMOS 4 PATRONES Y
BUSCAMOS ASOCIAR MATRICES
RUIDOSAS DE 5X5 CON ESOS
PATRONES ALMACENADOS**

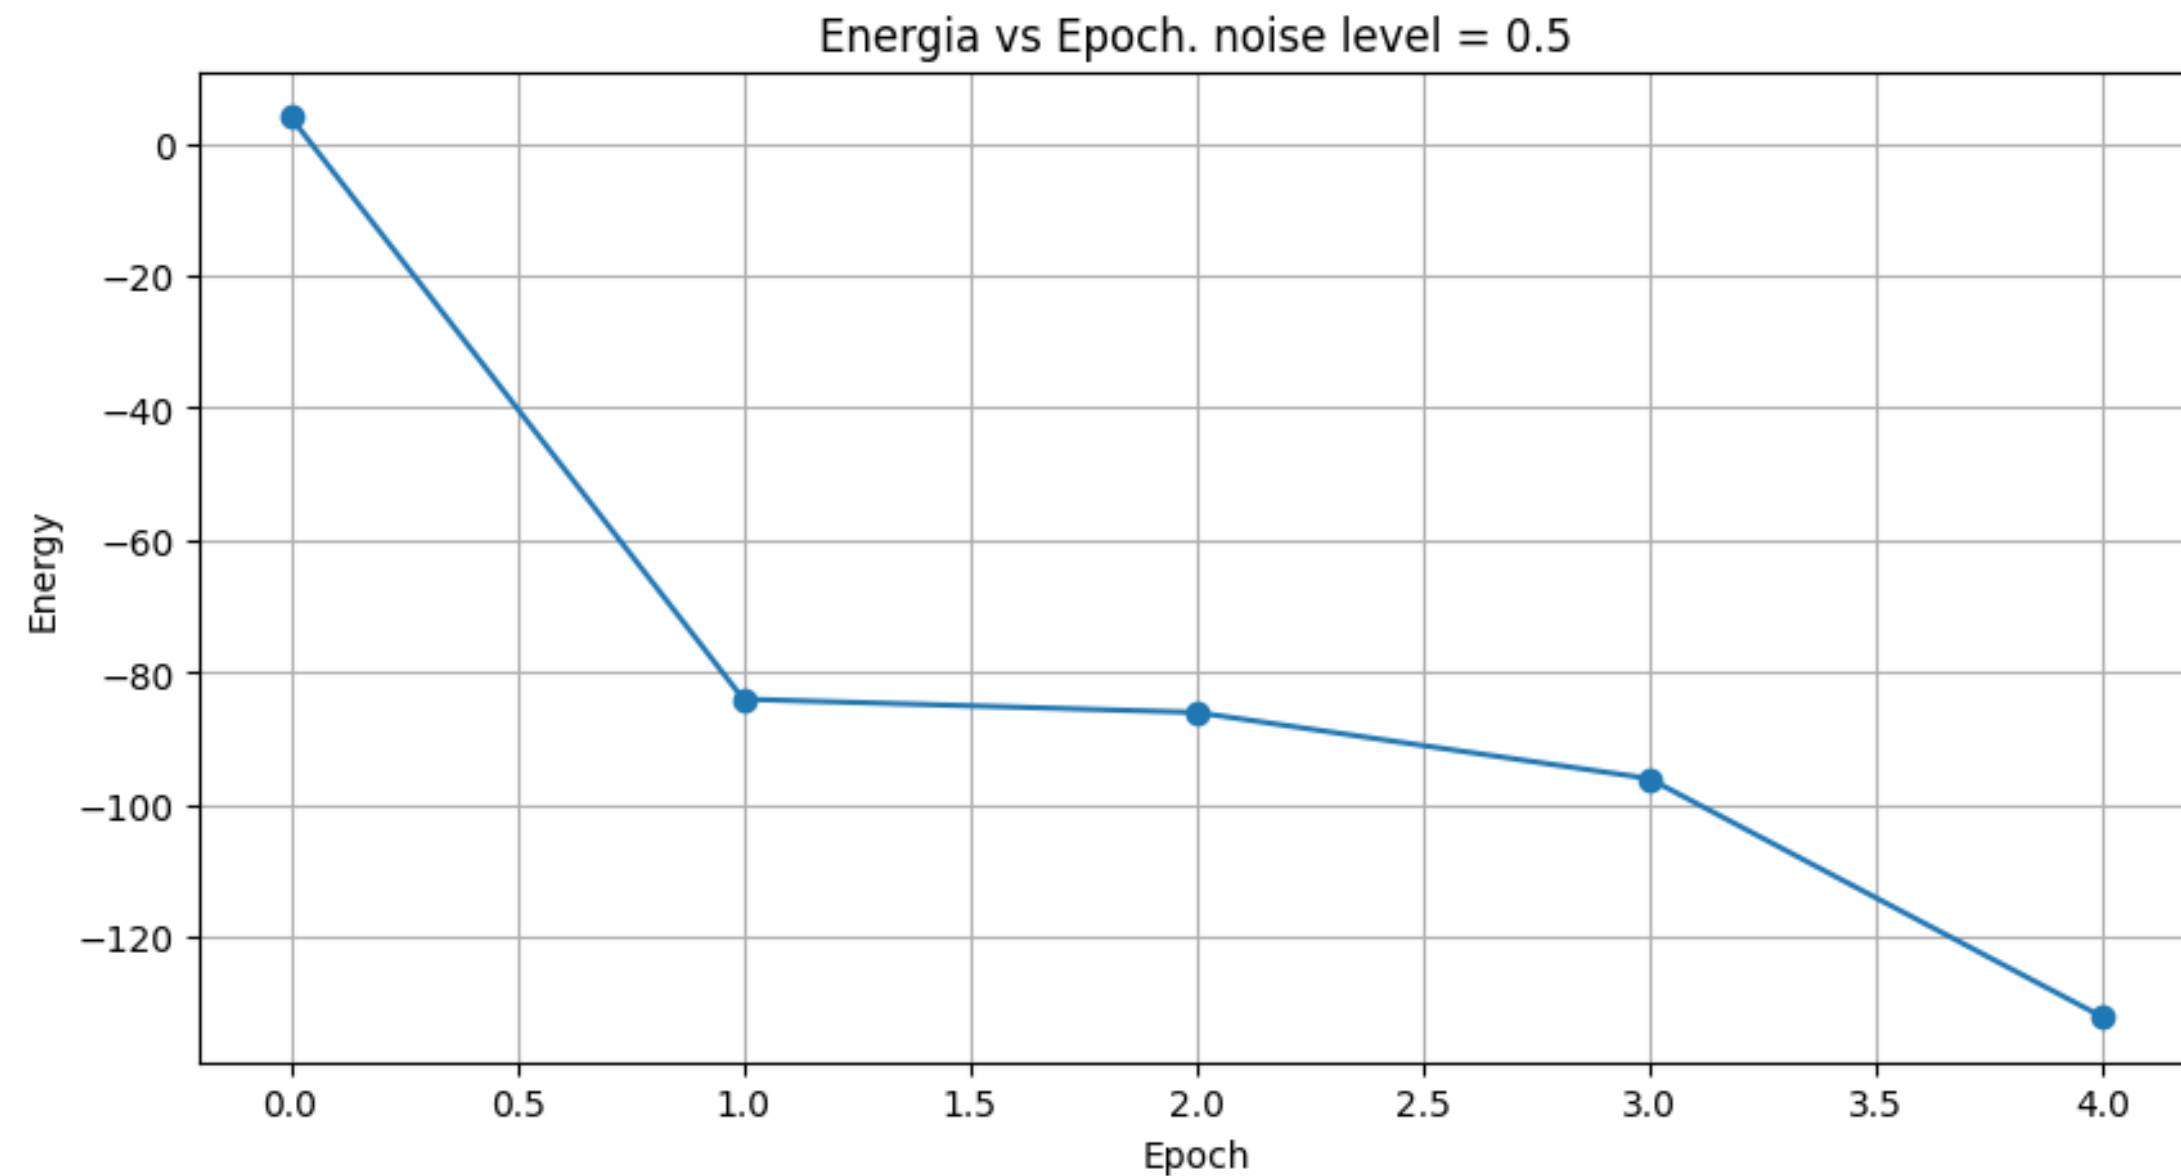
SET DE ENTRENAMIENTO

Se realizó el análisis con el código visto en clase, para tener en cuenta todas las posibles permutaciones de letras, y así determinar qué combinación es la mejor para almacenar en la red:

<,> medio	grupo
1.33	('L', 'R', 'T', 'X')
1.67	('F', 'I', 'U', 'X')
1.67	('I', 'L', 'R', 'X')
1.67	('I', 'R', 'U', 'X')
2.00	('F', 'I', 'L', 'X')



FUNCION DE ENERGIA




Letra: L
Ruido: 0.5

RECALL PARA LA LETRA: L

Recalls para la letra L. Noise level = 0.15. tolerance = 1e-06

Initial
Energy: -88.0




Epoch 1
Energy: -134.0




RECALL PARA LA LETRA: L

Recalls para la letra L. Noise level = 0.3. tolerance = 1e-06


Initial
Energy: -16.0



Epoch 1
Energy: -112.0




Epoch 2
Energy: -132.0




RECALL PARA LA LETRA: R

Recalls para la letra R. Noise level = 0.15. tolerance = 1e-06

Initial
Energy: -52.0




Epoch 1
Energy: -132.0




RECALL PARA LA LETRA: R

Recalls para la letra R. Noise level = 0.3. tolerance = 1e-06


Initial
Energy: 8.0




Epoch 1
Energy: -88.0



Epoch 2
Energy: -100.0




Epoch 3
Energy: -132.0




RECALL PARA LA LETRA: T

Recalls para la letra T. Noise level = 0.15. tolerance = 1e-06

Initial
Energy: -62.0




Epoch 1
Energy: -134.0




RECALL PARA LA LETRA: T

Recalls para la letra T. Noise level = 0.3. tolerance = 1e-06

Initial
Energy: -38.0




Epoch 1
Energy: -90.0




RECALL PARA LA LETRA: X

Recalls para la letra X. Noise level = 0.15. tolerance = 1e-06

Initial
Energy: -88.0




Epoch 1
Energy: -132.0




RECALL PARA LA LETRA: X

Recalls para la letra X. Noise level = 0.3. tolerance = 1e-06


Initial
Energy: -8.0



Epoch 1
Energy: -104.0



EFFECTO DEL RUIDO




Letra: R; Total de casos: 500

SET DE ENTRENAMIENTO 16X16


Letra L




Letra R




Letra T




Letra X



RESULTADOS 16X16




Ruido 0.3
Tolerancia 1e-06




Ruido 0.15
Tolerancia 1e-06

RESULTADOS 16X16




Ruido 0.3
Tolerancia 1e-06




Ruido 0.15
Tolerancia 1e-06

EFFECTO DEL RUIDO



Letra: R ; Total de casos: 500

NIVEL DE RUIDO 0.7



CONCLUSIONES

Cuanto más ortogonales sean los patrones, mejor asocia patrones ruidosos.

A medida que disminuye la ortogonalidad de los patrones almacenados, hay más posibilidades de convergencia a un estado espúreo.

Con alta probabilidad de ruido, existe la posibilidad de caer en estados espúreos, aún con patrones muy ortogonales.

Gracias