




TP 5: DEEP LEARNING



GRUPO 1:

Sol Victoria Anselmo


Julián Sasso

Agustín Mattiussi

Camila Sierra Pérez

Ian James Arnott

Juan Adolfo Rosauer Herrmann



0012 7482901 2744103 0592346 8774510 7255

LINEAL AUTOENCODER

Consideraciones:

Como ya habiamos analizado en el TP3, utilizaremos los parámetros de la siguiente manera:

Max Epochs: 10000

Bias: 1


Beta 1: 0.9

Beta 2: 0.999

Epsilon: $1e-8$


Optimizer: ADAM


Activation: Cosh



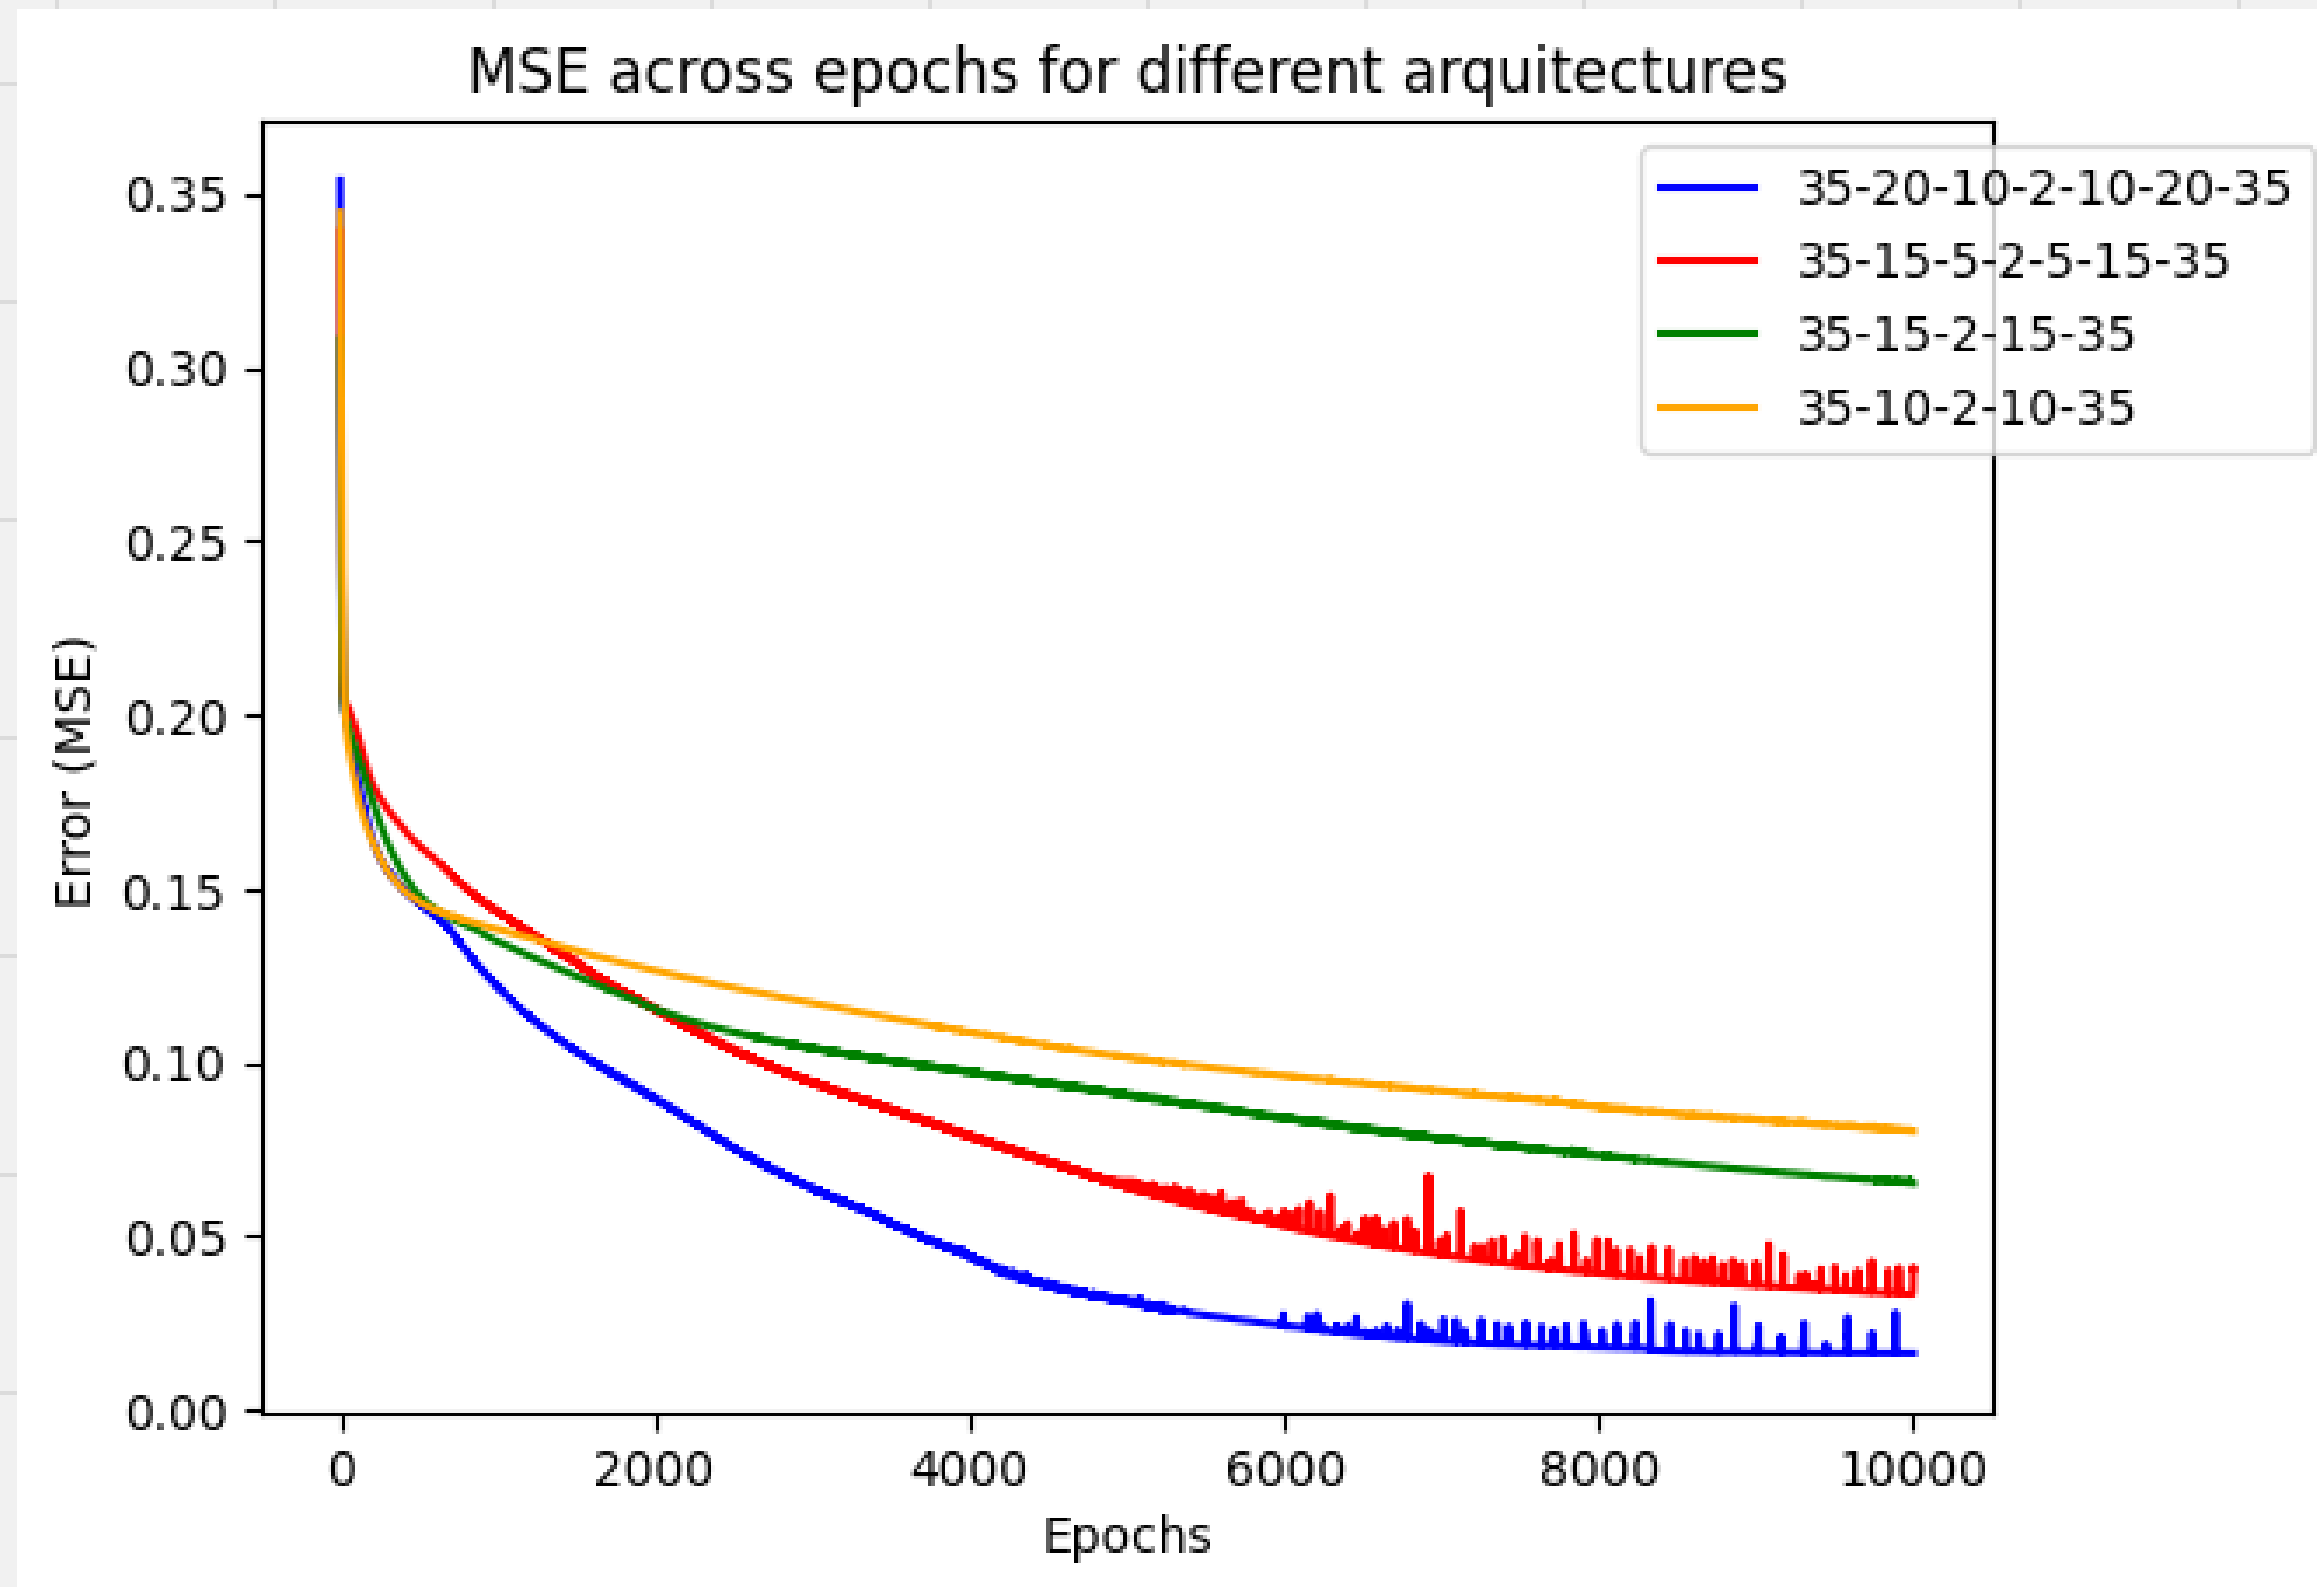
DATASET ORIGINAL


Caracteres Originales





VARIANDO LA CANTIDAD DE NODOS





VARIANDO EL LEARNING RATE

Learning rate = 0,01

Arquitectura: 35-20-10-2-10-20-35

Caracteres Predichos






Gráfico del Espacio Latente para cada Caracter



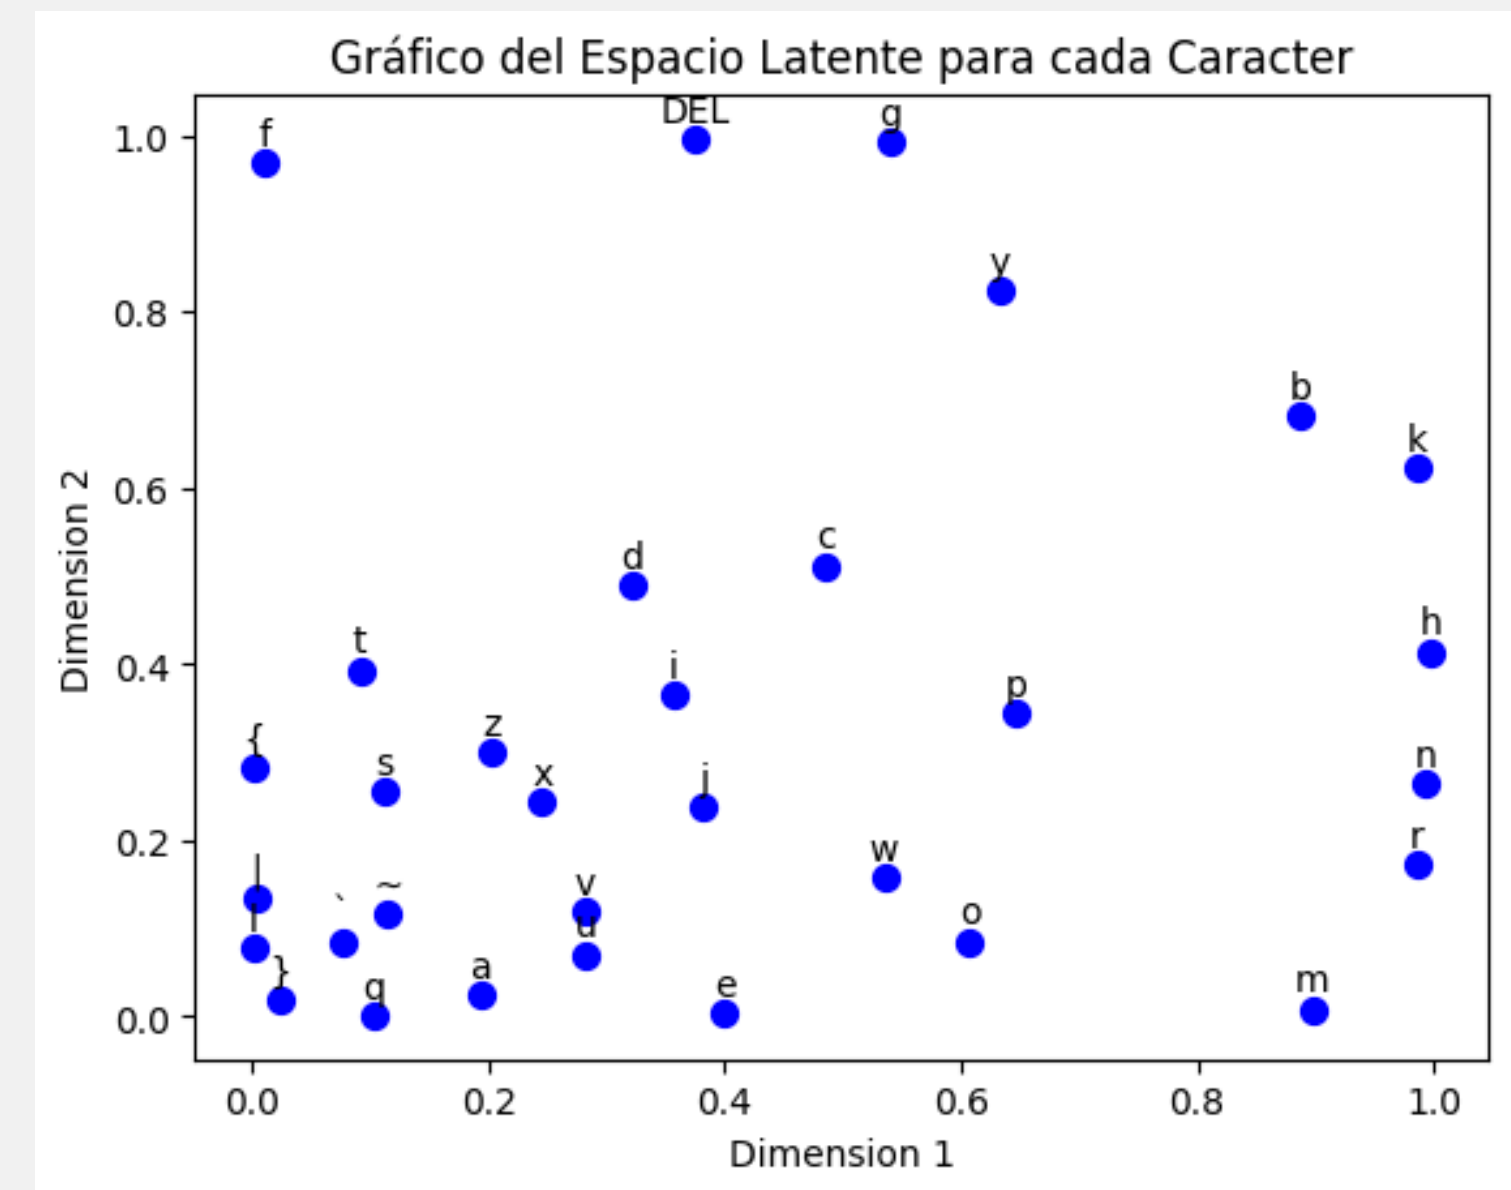
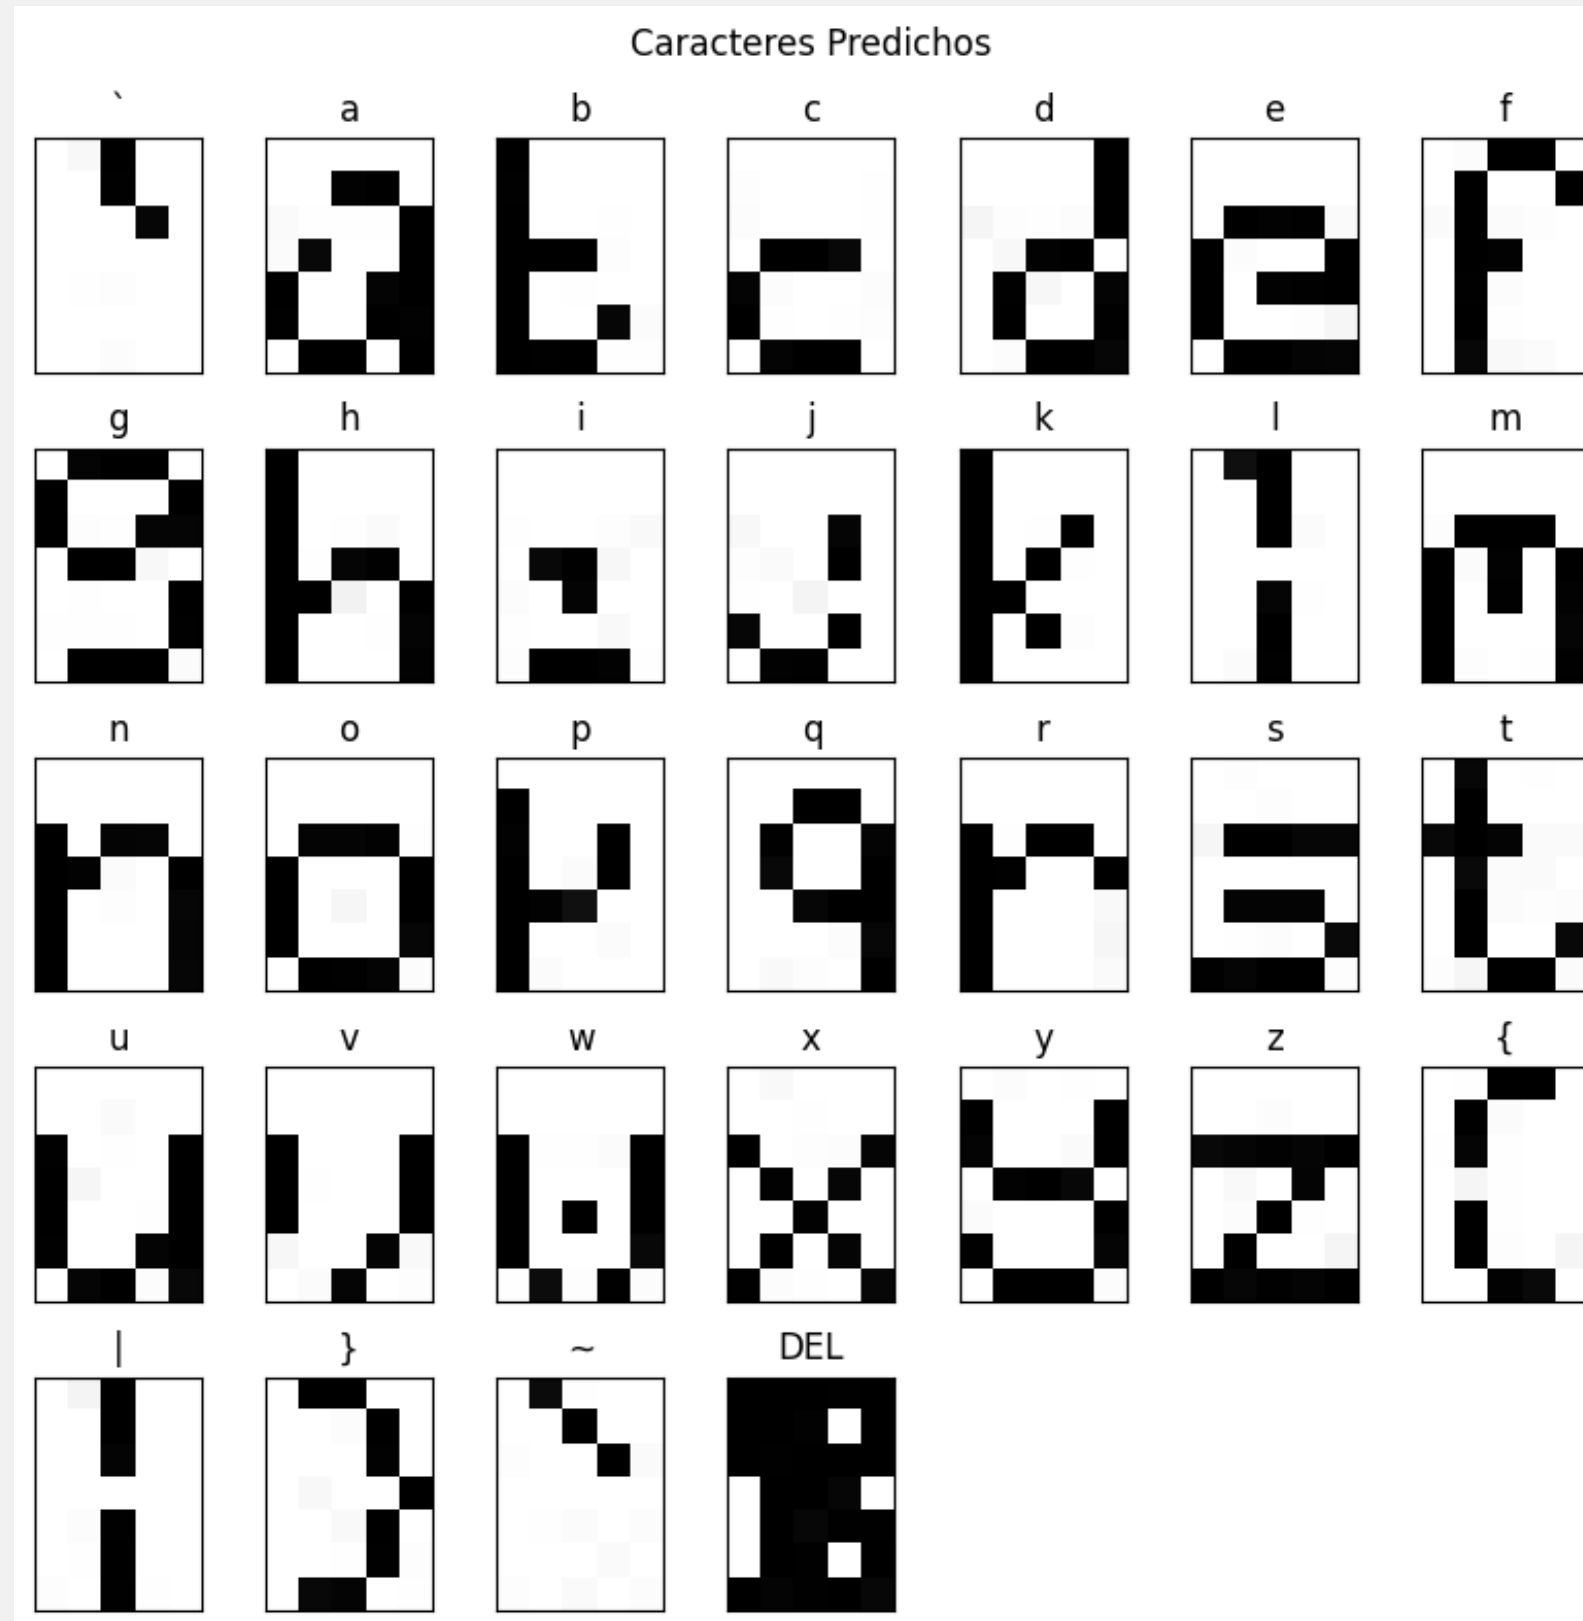



VARIANDO EL LEARNING RATE

Learning rate = 0,001

Arquitectura: 35-20-10-2-10-20-35

Error máximo de 1 pixel incorrecto


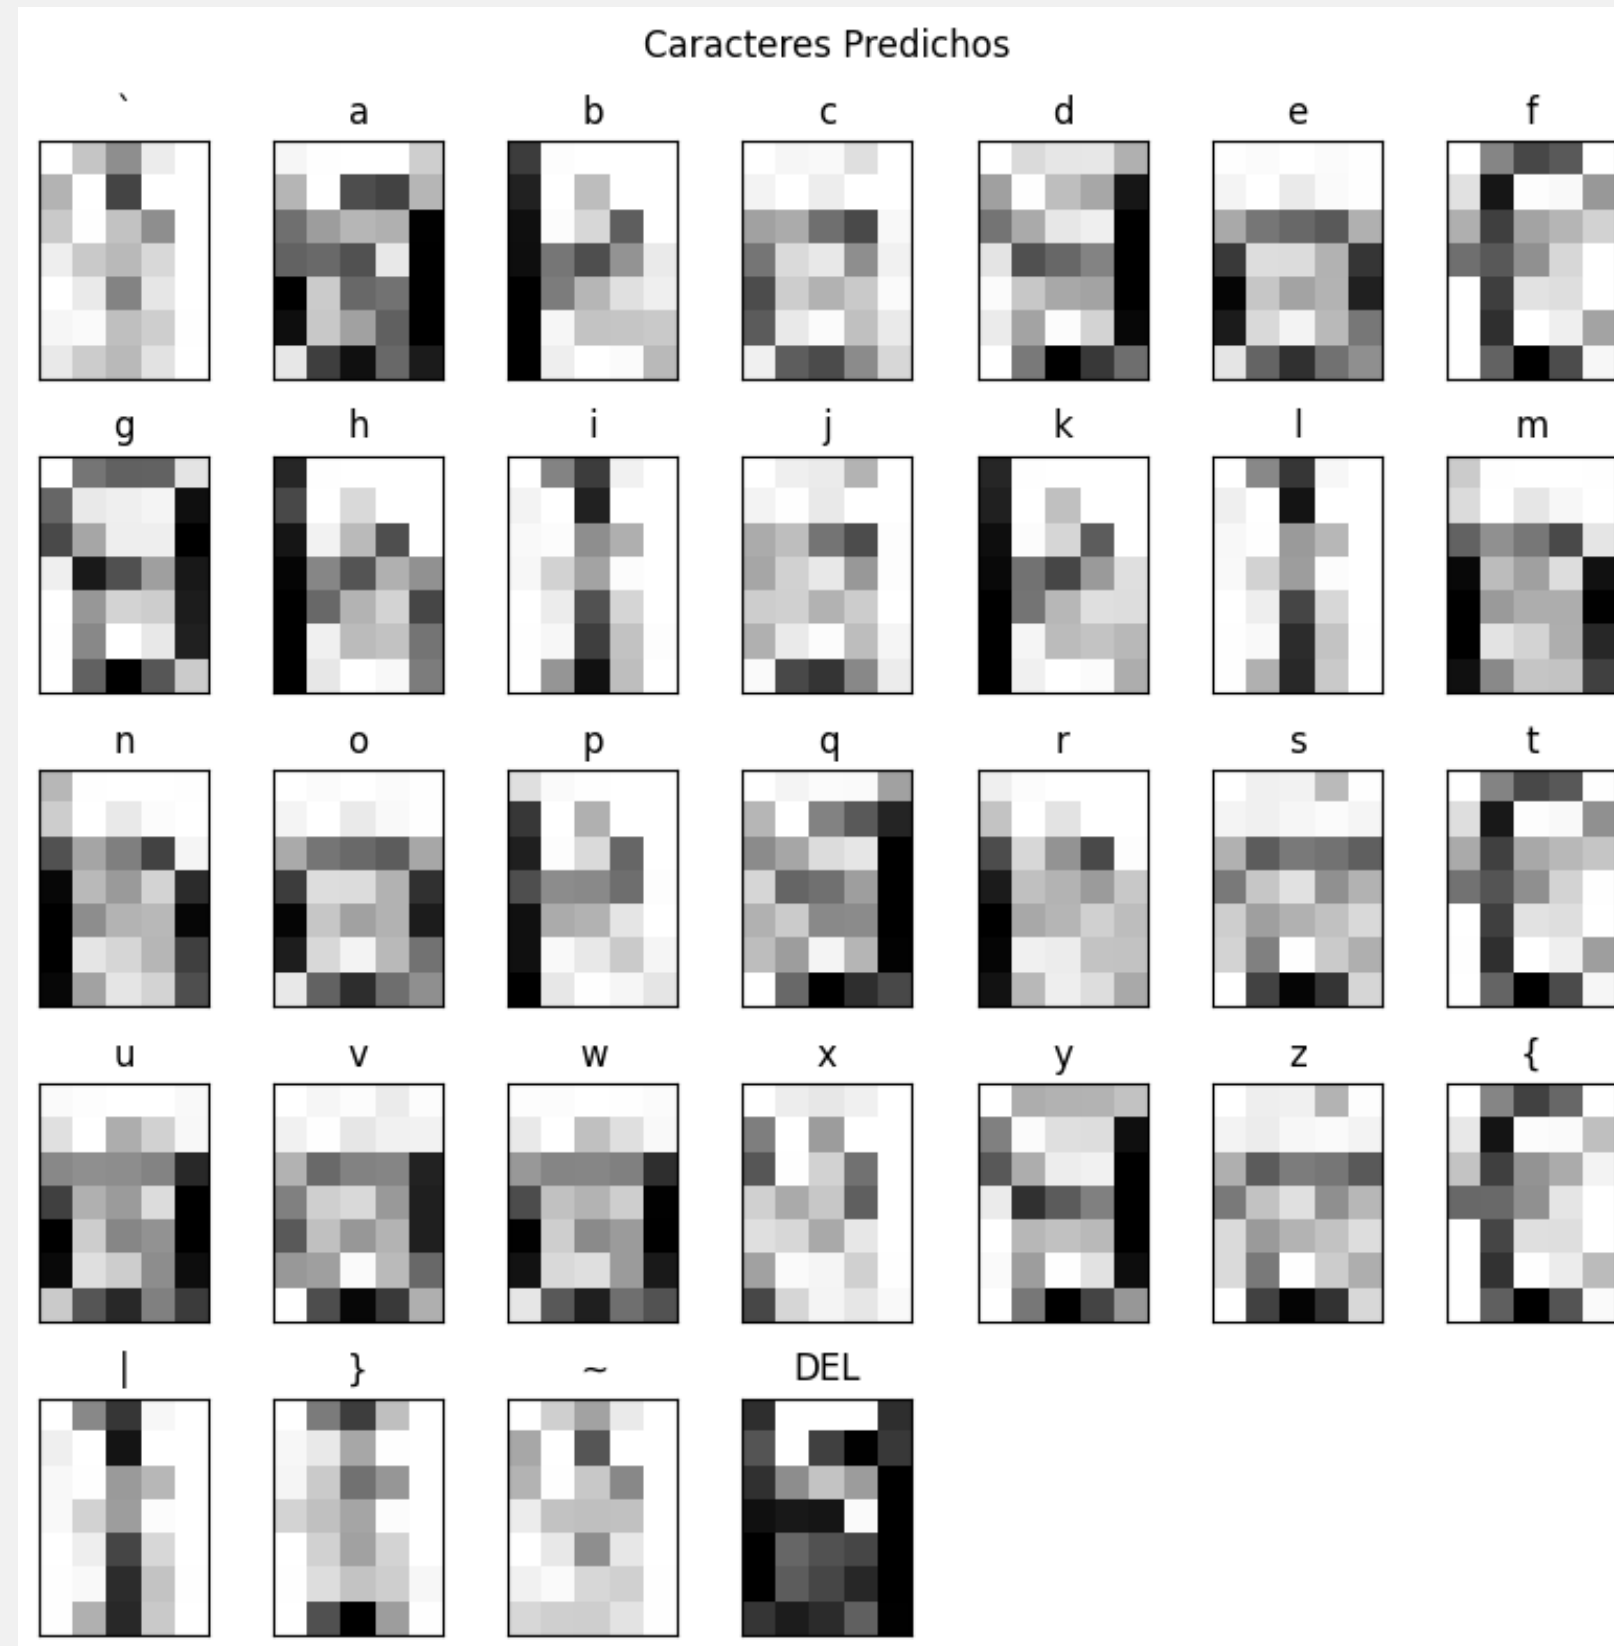




VARIANDO EL LEARNING RATE

Learning rate = 0,0001


Arquitectura: 35-20-10-2-10-20-35







CAPACIDAD DE GENERAR NUEVOS CARACTERES


Original @




Predicted @




Original A




Predicted A



Original +




Predicted +



Learning rate = 0,00001

Arquitectura: 35-20-10-2-10-20-35

Gráfico del Espacio Latente para cada Caracter



CONCLUSIONES



- No existe un número de capas ideal ni un número de neuronas por capa ideal.
 - Con una mayor cantidad de capas obtenemos mejores resultados, pero hay que tener en cuenta que esto aumenta el tiempo de aprendizaje.
- Las letras similares tienen codificaciones similares.
- No se pueden generar nuevos caracteres. Pero encontramos caracteres cercanos a nuestro espacio latente (deformaciones del conjunto de entrenamiento).

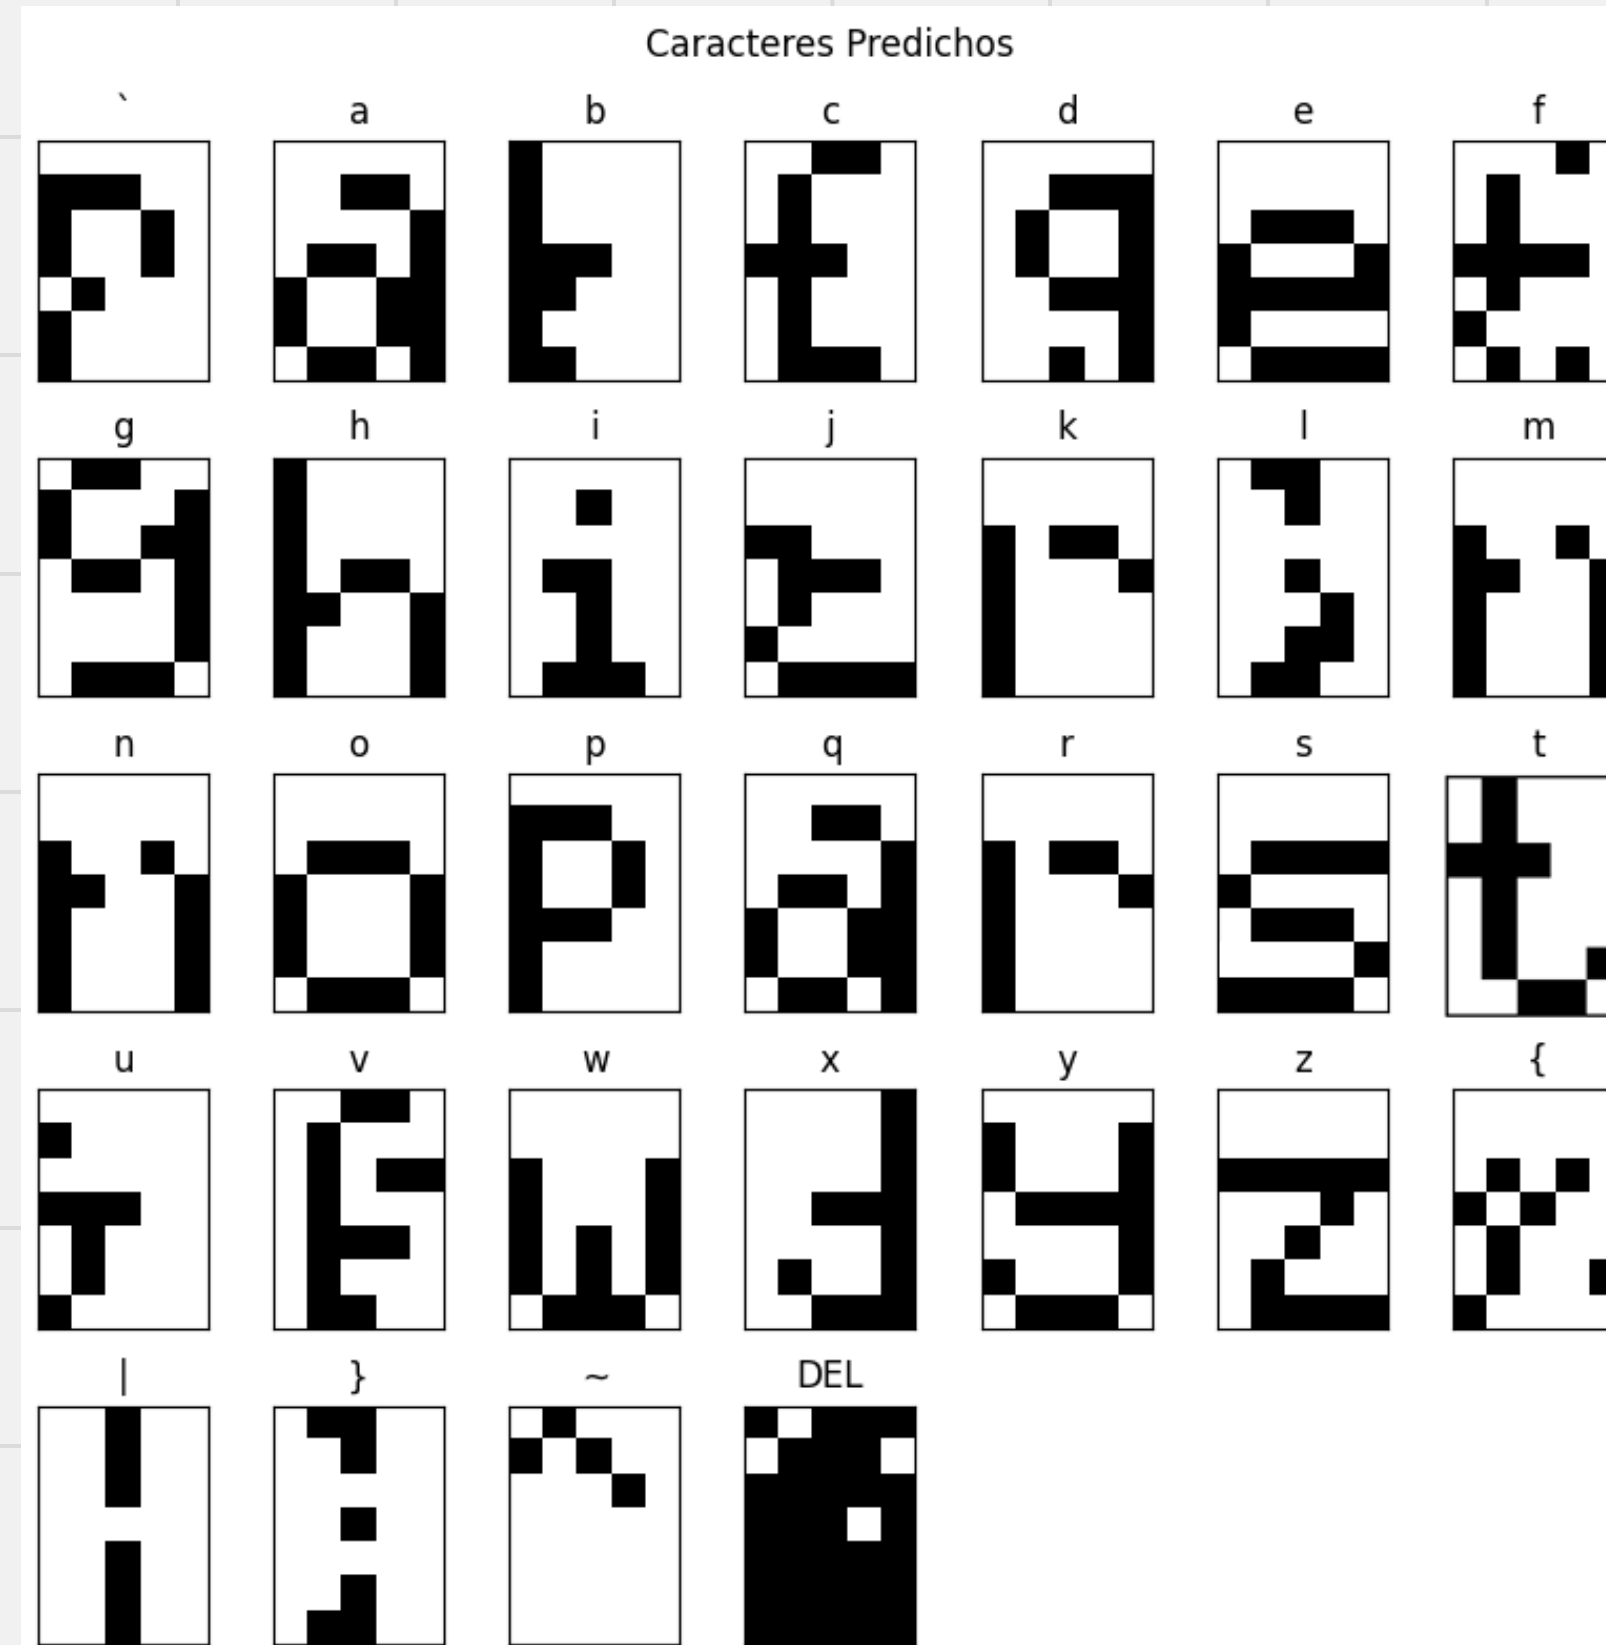



DENOISING AUTOENCODER

Consideraciones:

- Max Epochs: 10000
- Bias: 1
- Beta 1: 0.9
- Beta 2: 0.999
- Epsilon: $1e-8$
- Optimizer: ADAM
- Activation: Cosh
- Learning rate = 0,001
- Arquitectura: 35-20-10-2-10-20-35
- Ruido: Salt & Pepper

VARIANDO LA PROBABILIDAD DE MUTACIÓN



Ruido: 10%


Aciertos: 18/35
(~51%)

VARIANDO LA PROBABILIDAD DE MUTACIÓN


Ruido: 30%

Aciertos: 9/35 (~26%)


Original h Noisy h Predicted h



Original j Noisy j Predicted j




Original t Noisy t Predicted t




Ruido: 50%

Aciertos: 4/35 (~11%)


Original h Noisy h Predicted h



Original j Noisy j Predicted j



Original t Noisy t Predicted t



CONCLUSIONES



- Aumentar la probabilidad de S&P por un nivel superior al 20% puede provocar que los elementos muten a algo irreconocible.
 - A mayor ruido, más le cuesta asociar las entradas a la red.
- Se observaron buenos resultados cuando los caracteres parecen preservar “la forma” al ser afectados por el ruido.
 - En estos casos el DAE logra reconstruir caracteres con un nivel de ruido significativo.
- Como se mencionó en entregas anteriores, al trabajar con imágenes de tan baja resolución (7x5), aunque el porcentaje de ruido sea muy chico, este puede afectar de forma significativa la forma de la imagen original



VARIATIONAL AUTOENCODER

Consideraciones:

- **Max Epochs:** 1000
- **Bias:** 1
- **Beta 1:** 0.9
- **Beta 2:** 0.999
- **Epsilon:** $1e-8$
- **Optimizer:** ADAM
- **Activation:**
 - ReLU para las capas intermedias
 - Cosh para la capa de salida
- **Learning rate** = 0,001









DATASET & ARQUITECTURE

- Conjunto de logos de redes sociales.
- Imágenes de 20x20 en escala de grises.



- Arquitectura:
400-300-200-100-20-100-200-300-400


RESULTADOS OBTENIDOS




ESPACIO LATENTE




"tiktok" -> "whatsapp"



"twitter" -> "tiktok"




"linkedin" -> "facebook"



ESPACIO LATENTE DE 2 DIMENSIONES

Nos movemos del punto
 $(-0.5, -0.5)$ al $(1.3, 1.3)$
con un paso de 0.2



CONCLUSIONES

- Los VAEs permiten generar nuevas muestras y realizar interpolaciones suaves sobre todo el espacio latente.
- La representación del espacio latente en un autoencoder no variacional no tiene una estructura probabilística, lo que limita la capacidad de generar nuevas muestras.

